



Elogios de Engineering

Este libro ofrece una guía completa y bien estructurada de los aspectos esenciales de la construcción de sistemas de IA generativa. Una lectura obligada para cualquier profesional que busque escalar la IA en toda la empresa.

·Vittorio Cretella, ex CIO global, P&G y Mars

Chip Huyen se adentra en la IA generativa. Además de eso, es una maestra y escritora notable cuyo trabajo ha sido fundamental para ayudar a los equipos a llevar la IA a producción.

Basándose en su profunda experiencia, el libro sirve como una guía completa y holística, detallando magistralmente todo lo necesario para diseñar y desplegar aplicaciones de IA generativa en producción.

·Luke Metz, cocreador de ChatGPT,
ex gerente de investigación en OpenAI

Todo ingeniero de IA que construya aplicaciones del mundo real debe leer este libro. Es una guía vital para el diseño de sistemas de IA de extremo a extremo, desde el diseño y la evaluación hasta el despliegue y la operación a gran escala.

·Andrei Lopatenko, Director de Búsqueda e IA, Neuron7

Este libro sirve como una guía esencial para construir productos de IA que puedan escalar. A diferencia de otros libros que se centran en herramientas o tendencias actuales que cambian rápidamente, Chip ofrece conocimiento fundamental atemporal. Ya sea que sea un gerente de producto o un ingeniero, este libro cierra efectivamente la brecha de colaboración entre equipos multifuncionales, lo que lo convierte en un recurso indispensable involucrado en el desarrollo de IA.

·Aileen Bui, Gerente de Operaciones de Producto de IA, Google

¡Esta es la transición definitiva al ingeniería de IA desde una de las grandes del ingeniería de ML
Chip ha visto proyectos y carreras exitosos en cada etapa de una empresa y
por primera vez condensó su experiencia para los nuevos Ingenieros de IA que ingresan al ca
·swyx, Curator, AI.Engineer

AI Engineering es una guía práctica que proporciona la información más actualizada sobre el des
haciéndola accesible tanto para líderes novatos como expertos. Este libro
es un recurso esencial para cualquiera que busque construir sistemas de IA robustos y es
·Vicki Reyzelman, Chief AI Solutions Architect, Mave Sparks

AI Engineering es una guía completa que sirve como referencia esencial
tanto para comprender como para implementar sistemas de IA en la práctic
·Han Lee, Director·Data Science, Moody·s

AI Engineering es una guía esencial para cualquiera que construya software con Generative AI
Desmitifica la tecnología, destaca la importancia de la evaluación y comparte
lo que se debe hacer para lograr calidad antes de comenzar con el costoso fine-tuning
·Rafal Kawala, Senior AI Engineering Director, 16 años de
experiencia trabajando en una empresa Fortune 500

AI Engineering

Building Applications with Foundation Models

Chip Huyen

AI Engineering
por Chip Huyen

Copyright © 2025 Developer Experience Advisory LLC. Todos los derechos reservados.

Impreso en los Estados Unidos de América.

Publicado por O'Reilly Media, Inc., 1005 Gravenstein Highway North, Sebastopol, CA 95472.

Los libros de O'Reilly pueden comprarse para uso educativo, comercial o promocional de ventas. Las ediciones en
también disponibles para la mayoría de los títulos (obtener más información, contacte a nuestro departamento de v
corporate@oreilly.com . Editor de Adquisiciones:

Nicole Butterfield

Melissa Potter Diseñador de Interiores:

Beth Kelly Diseñador de Portada:

Liz Wheeler

Piper Editorial, LLC

Word Collection, Inc.

David Futato Editor de Producción:

Karen Montgomery

Kate DuBois

Primera Edición Historial de Revisiones para la Primera Edición

2024-12-04: Primer Lanzamiento

Consulte

<http://oreilly.com/catalog/errata.csp?isbn=9781098166304> El logotipo de O'Reilly es una marca registrada de O'Reilly

AI Engineering , la imagen de la portada y el texto "O'Reilly" relacionado son marcas

Las opiniones expresadas en esta obra son las del autor y no representan las opiniones de la editorial.

Si bien la editorial y el autor han hecho esfuerzos de buena fe para garantizar que la información y
las instrucciones contenidas en esta obra sean precisas, la editorial y el autor renuncian a toda responsabilidad
por errores u omisiones, incluida, entre otras, la responsabilidad por daños resultantes del uso de
o la confianza en esta obra. El uso de la información e instrucciones contenidas en esta obra es bajo su propio
riesgo. Si cualquier muestra de código u otra tecnología que contiene o describe esta obra está sujeta a licencias d
o a los derechos de propiedad intelectual de terceros, es su responsabilidad garantizar que su uso
cumpla con dichas licencias y/o derechos.

978-1-098-16630-4

978-1-098-16630-4

[LSI]

Tabla de Contenido

1.

2.

3.

4.

5.

6.

7.

8.

9.

10.

Prefacio

Cuando ChatGPT salió, como muchos de mis colegas, me sentí desorientado. Lo que me sorprendió no fue el tamaño o las capacidades del modelo. Durante más de una década, la comunidad de IA ha sabido que escalar un modelo lo mejora. En 2012, los autores de AlexNet señalaron en [1] que: «Todos nuestros experimentos sugieren que nuestros resultados pueden mejorarse simplemente esperando que las GPUs más rápidas y los conjuntos de datos estén disponibles».

Lo que me sorprendió fue la gran cantidad de aplicaciones que impulsó este aumento de capacidad. No solo estas nuevas capacidades de IA han aumentado la demanda de aplicaciones de IA, sino que también han reducido la barrera de entrada para los desarrolladores. Se ha vuelto tan fácil como escribir código.

Aunque la adopción de la IA hoy parece nueva, se basa en técnicas que han estado en uso durante un tiempo. Los artículos sobre modelado de lenguaje salieron a principios de los 2010. Las aplicaciones de Retrieval-augmented generation (RAG) se construyen sobre la tecnología de IA [2].

Un autor del artículo de AlexNet, Ilya Sutskever, continuó cofundando OpenAI, convirtiendo esta lección en realidad con GPT [3].

Incluso en el MIT, donde se creó el primer modelo de lenguaje, se usó para evaluar la calidad de la traducción [4]. Incluso mi pequeño proyecto en 2017, que utilizó un modelo de lenguaje para evaluar la calidad de la traducción [5], se benefició de esta tecnología.

RAG was coined. The best practices for deploying traditional machine learning applications—systematic experimentation, rigorous evaluation, relentless optimization for faster and cheaper models—are still the best practices for working with foundation model-based applications.

1 An author of the AlexNet paper, Ilya Sutskever, went on to cofound OpenAI, turning this lesson into reality with GPT models.

2 Even Google Translate, which used a language model to evaluate translation quality, concluded that we needed «a better language model».

La familiaridad y facilidad de uso de muchas técnicas de ingeniería de IA pueden llevar a las Pero si bien muchos principios para construir aplicaciones de IA siguen siendo los mismos, la escala y las capacidades mejor los modelos de IA introducen oportunidades y desafíos que requieren nuevas soluciones.

Este libro cubre el proceso de extremo a extremo de adaptar los modelos fundacionales para mundo real, abarcando técnicas probadas de otros campos de ingeniería y técnicas emergentes con los modelos fundacionales.

Me propuse escribir el libro porque quería aprender, y aprendí mucho. Aprendí de los proyectos en los que trabajé, los artículos que leí y las personas a las que entrevisté. Durante el proceso de escribir este libro, utilicé notas de más de 100 conversaciones e entrevistas, incluidos investigadores de laboratorios importantes de IA (OpenAI, Google, Anthropic, ...), desarrolladores de frameworks (NVIDIA, Meta, Hugging Face, Anyscale, LangChain, LlamaIndex, ...), ejecutivos y jefes de IA/datos en empresas de diferentes tamaños, gerentes de producto, investigadores de la comunidad y desarrolladores de aplicaciones independientes (ver [ver](#)).

Aprendí especialmente de los primeros lectores que probaron mis suposiciones, me presentaron diferentes perspectivas y me expusieron a nuevos problemas y enfoques. Algunas secciones después de ser compartidas en mi blog [hipótesis](#).

Espero que este proceso de aprendizaje continúe para mí ahora que el libro está en sus manos, ya que tienen experiencias y perspectivas que son únicas para ustedes. Por favor, siéntanse libres de compartir cualquier comentario que puedan tener sobre este libro conmigo en [X](#) [LinkedIn](#) hi@huyenchip.com.

Este libro proporciona un marco para adaptar los modelos fundacionales.

large language models (LLMs) como large multimodal models

Hay muchas maneras diferentes de construir una aplicación. Este libro describe varias soluciones y también plantea preguntas que pueden hacer para evaluar la mejor solución para sus necesidades. Algunas de las muchas preguntas que este libro puede ayudarle a responder son:

¿Debería construir esta aplicación de IA?

¿Cómo evalúo mi aplicación? ¿Puedo usar IA para evaluar las salidas de IA?

¿Qué causa las alucinaciones? ¿Cómo detecto y mitigo las alucinaciones?

¿Cuáles son las mejores prácticas para la prompt engineering?

¿Por qué funciona RAG? ¿Cuáles son las estrategias para hacer RAG?

| Prefacio

- ¿Qué es un agente? ¿Cómo construyo y evalúo un agente?
- ¿Cuándo ajustar (finetune) un modelo? ¿Cuándo no ajustar un modelo?
- ¿Cuántos datos necesito? ¿Cómo valido la calidad de mis datos?
- ¿Cómo hago que mi modelo sea más rápido, más barato y más seguro?
- ¿Cómo creo un bucle de retroalimentación para mejorar continuamente mi aplicación?

El libro también le ayudará a navegar por el abrumador panorama de la IA: tipos de modelos, benchmarks de evaluación y un número aparentemente infinito de casos de uso y patrones de El contenido de este libro está ilustrado con estudios de caso, muchos de los cuales trabajé,

respaldados por amplias referencias y examinados exhaustivamente por expertos de una am antecedentes. Aunque el libro tomó dos años escribirlo, se basa en mi experiencia trabajando Como mi libro anterior de O'Reilly, Diseñando Sistemas de Aprendizaje Automático

(DMLS), este libro se centra en los fundamentos de la ingeniería de IA. A lo largo de la lectura, (DMLS), este libro se centra en los fundamentos de la ingeniería de IA. A lo largo de la lectura, 3 Ingeniería de IA Lectura

(AIE) Diseñando Sistema (DMLS) Aprendizaje Automático (DMLS) AIE puede ser un complemento de DMLS. DMLS s

AIE can be a companion to DMLS. DMLS focuses on building applications on top of traditional ML models, which involves more tabular data annotations, feature engineering, and model training. AIE focuses on building applications on top of foundation models, which involves more prompt engineering, context construction, and parameter-efficient finetuning. Both books are self-contained and modular, so you can read either book independently.

Dado que los modelos fundacionales son modelos de ML, algunos conceptos son relevantes para ambos. Si un tema es relevante para AIE pero se ha discutido extensamente en DMLS, aún se Tenga en cuenta que muchos temas se cubren en DMLS pero no en AIE, y viceversa. El primer

3
|

Prefacio

and foundation models, so knowledge about working with both is often necessary.

3 Teaching a course on how to use TensorFlow in 2017 taught me a painful lesson about how quickly tools and tutorials become outdated.

Determinar si algo durará, sin embargo, a menudo es desafiante. Me basé en tres criterios. Primero, para un problema, determiné si resulta de las limitaciones fundamentales es fundamental, analizaré sus desafíos y soluciones para abordar cada desafío. Soy un fan del enfoque start-simple, así que para muchos problemas, empezaré con la solución más simple y luego progresaré con soluciones más complejas para abordar los desafíos. Segundo, consulté una extensa red de investigadores e ingenieros, que son

más inteligentes que yo, sobre lo que consideran los problemas y soluciones más importantes.

Ocasionalmente, también me basé en

Ley de Lindy de una tecnología es proporcional a su edad actual. Así que, por un tiempo, asumo que continuará existiendo por más tiempo.

Sin embargo, en este libro, ocasionalmente incluí un concepto que creo que es temporal

porque es inmediatamente útil para algunos desarrolladores de aplicaciones o porque ilustra un interesante enfoque de resolución de problemas.

Lo que Este Libro No Es

Este libro no es un tutorial. Si bien menciona herramientas

para ilustrar ciertos conceptos, no te enseña a usar una herramienta. En su lugar, ofrece un marco para seleccionar herramientas. Incluye muchas discusiones sobre las complejidades de la solución. Cuando quieras usar una herramienta, generalmente es fácil encontrar tutoriales para ella. Los chatbots de IA también son bastante buenos para ayudarte a empezar con herramientas. Este libro no es un libro de teoría de ML. No explica qué es una red neuronal ni cómo construir y entrenar un modelo desde cero. Si bien explica muchos conceptos teóricos

inmediatamente relevantes para la discusión, el libro es un libro práctico que se centra en ayudarte a construir aplicaciones de IA exitosas para resolver problemas del mundo real. Si bien es posible construir aplicaciones basadas en modelos fundacionales sin experiencia e incluso sin sufrir innecesario. Puedes leer este libro sin ningún conocimiento previo de ML si conoces los siguientes conceptos:

- Conceptos probabilísticos como muestreo, determinismo y distribución.
-

Conceptos de ML como supervisión, auto-supervisión, log-likelihood, descenso de gradiente,

xiv

| Prólogo

descent, backpropagation, loss function, and hyperparameter tuning.

- Diversas arquitecturas de redes neuronales, incluyendo feedforward, recurrent y transformer.
- Métricas como accuracy, F1, precision, recall, cosine similarity y entropía cruzada. Si aún no las conoces, no te preocupes: este libro tiene explicaciones breves y de alto nivel.

Para Quién Es Este Libro

Este libro es para cualquiera que quiera aprovechar los modelos fundacionales para resolver

roles técnicos, incluidos ingenieros de IA, ingenieros

uno de los siguientes escenarios:

· Estás construyendo u optimizando una aplicación de IA, ya sea comenzando desde cero o mejorando una existente.

· Quieres optimizar el proceso de desarrollo de IA de tu equipo, haciéndolo más sistemático, reproducible y eficiente.

- Quieres comprender cómo tu organización puede aprovechar los modelos fundacionales para mejorar sus procesos. También puedes beneficiarte del libro si perteneces a uno de los siguientes grupos:

· Desarrolladores de herramientas que desean identificar áreas desatendidas en la ingeniería de IA.

- Investigadores que desean comprender mejor los casos de uso de la IA.

· Candidatos a puestos de trabajo que buscan claridad sobre las habilidades necesarias para trabajar en IA.

Cualquiera que quiera comprender mejor las capacidades y limitaciones de la IA, y cómo

podría afectar a diferentes roles.

· Prefiero llegar al fondo de las cosas, por lo que algunas secciones profundizan un poco más en los detalles.

· Researchers who want to better understand AI use cases.

- Job candidates seeking clarity on the skills needed to pursue a career as an AI engineer.
- Anyone wanting to better understand AI's capabilities and limitations, and how it might affect different roles.

I love getting to the bottom of things, so some sections dive a bit deeper into the technical side. While many early readers like the detail, it might not be for everyone. I'll give you a heads-up before things get too technical. Feel free to skip ahead if it feels a little too in the weeds!

Navegando este libro

Este libro está estructurado para seguir el proceso típico para desarrollar una aplicación de IA. Esto es lo que parece este proceso típico y cómo encaja cada capítulo en el proceso. Debido a que este libro es modular, eres bienvenido a omitir cualquier sección que ya estés familiarizado o que sea menos relevante para ti.

Antes de decidir construir una aplicación de IA, es necesario comprender qué implica este proceso y responder preguntas como: ¿Es necesaria esta aplicación? ¿Se necesita IA? ¿Tengo que construir esta aplicación yo mismo? El primer capítulo del libro te ayuda a responder estas preguntas. También cubre una variedad de casos de uso exitosos y una idea de lo que pueden hacer los foundation models.

Si bien un background en ML no es necesario para construir aplicaciones de IA, comprender cómo funciona un foundation model bajo el capó es útil para sacarle el máximo provecho.

El capítulo 2 analiza la creación de un foundation model y las decisiones de diseño con impactos significativos en las aplicaciones posteriores (downstream applications), incluida su arquitecturas de modelo y escalas, y cómo se entrena el modelo para alinearse con las preferencias. El capítulo 3 discute cómo un modelo genera una respuesta, lo que ayuda a explicar los comportamientos del modelo, como la inconsistencia y las alucinaciones. Cambiar la configuración de generación puede aumentar significativamente el rendimiento del modelo.

Una vez que te has comprometido a construir una aplicación con foundation models, la evaluación será una parte integral de cada paso en el camino. La evaluación es uno de los desafíos más

Capítulo

3

y **Capítulo 4**, para explorar diferentes métodos de evaluación de la respuesta de un modelo que depende de los prompts (fuera de la configuración de generación del modelo):

.

Las instrucciones sobre cómo debe comportarse el modelo

- El contexto que el modelo puede usar para responder a la consulta
- El modelo en sí

El siguiente tres capítulos del libro se centran en una aplicación para optimizar cada uno de estos aspectos.

Capítulo 5

cubre prompt engineering, comenzando por qué es un **Capítulo 6** qué funciona el prompt engineering y explora por qué el contexto es importante para que un modelo genere respuestas precisas. Se introduce el patrón RAG se entiende mejor y ha demostrado funcionar bien en producción. Por último, el capítulo 7 trata sobre cómo adaptar un modelo a una aplicación cambiando el modelo en sí mismo con menos memoria. El capítulo cubre diferentes enfoques de finetuning, complementados por una sección más técnica que muestra cómo calcular la huella de memoria de un modelo.

El capítulo 8 trata sobre cómo adaptar un modelo a una aplicación cambiando el modelo en sí mismo con menos memoria. El capítulo cubre diferentes enfoques de finetuning, complementados por una sección más técnica que muestra cómo calcular la huella de memoria de un modelo.

Debido a la naturaleza modular del libro, la configuración de datos para cada capítulo es diferente y puede seguir el proceso de desarrollo de la aplicación de IA.

Convenciones Utilizadas en Este Libro

Las siguientes convenciones tipográficas se utilizan en este libro:

Indica nuevos términos, URLs, direcciones de correo electrónico, nombres de archivo

Preface

|

xvii

plemented by a more experimental approach: model merging. This chapter contains a more technical section that shows how to calculate the memory footprint of a model.

Due to the availability of many finetuning frameworks, the finetuning process itself is often straightforward. However, getting data for finetuning is hard. The next chapter is all about data, including data acquisition, data annotations, data synthesis, and data processing. Many of the topics discussed in are relevant beyond finetuning, including the question of what data quality means and how to evaluate the quality of your data.

If Chapters to are about improving a model's quality, is about making its inference cheaper and faster. It discusses optimization both at the model level and inference service level. If you're using a model API*i.e.*, someone else hosts your model for you, this API will likely take care of inference optimization for you. However, if you host the model yourself—either an open source model or a model developed in-house—you'll need to implement many of the techniques discussed in this chapter.

The last chapter in the book brings together the different concepts from this book to build an application end-to-end. The second part of the chapter is more product-focused, with discussions on how to design a user feedback system that helps you collect useful feedback while maintaining a good user experience.



I often use *we* in this book to mean you (the reader) and I. It's a habit I got from my teaching days, as I saw writing as a shared learning experience for both the writer and the readers.

Conventions Used in This Book

The following typographical conventions are used in this book:

Italic

Indicates new terms, URLs, email addresses, filenames, and file extensions.

Ancho constante

Se utiliza para listados de programas, así como dentro de párrafos para referirse a elementos.

Ancho constante en negrita

Muestra comandos u otro texto que debe ser escrito literalmente por el usuario.

Ancho constante en cursiva

Muestra texto que debe ser reemplazado con valores suministrados por el usuario o por valores predeterminados.

Este elemento significa una sugerencia o consejo.

Este elemento significa una nota general.

Este elemento indica una advertencia o precaución.



Uso de Ejemplos de Código



El material complementario (ejemplos de código, ejercicios, etc.) está disponible para el lector.



<https://github.com/chiphuyen/aie-book>

. El repositorio contiene recursos adicionales sobre

escribir este libro, el repositorio de GitHub también contiene información detrás de escena y el correo electrónico support@oreilly.com.

. Este libro está aquí para ayudarte a hacer tu trabajo. En general, si se ofrece código de ejemplo con este libro, puedes usarlo en tus programas y documentación. No necesitas contactarnos para pedir permiso a menos que estés reproduciendo una porción significativa del código. Por ejemplo, escribir un programa que use varios fragmentos de código de

|

Preface

This book is here to help you get your job done. In general, if example code is offered with this book, you may use it in your programs and documentation. You do not need to contact us for permission unless you're reproducing a significant portion of the code. For example, writing a program that uses several chunks of code from